

# Test Wilcoxona

Mateusz Lewko

6 czerwca 2018

## 1 Wstęp

Test sumy rang Wilcoxona służy do sprawdzenia, czy wartości próbek pobranych z dwóch niezależnych populacji są jednakowo duże. Innymi słowy, pozwala sprawdzić, czy dwie losowo wybrane próbki zostały wybrane z populacji o takim samym rozkładzie.

### 1.1 Konieczne założenia

1. Wszystkie obserwacje z obydwu grup są od siebie niezależne.
2. Obserwacje możemy porównać i uporządkować.
3. Hipoteza zerowa: obserwacje pochodzą z populacji o takim samym rozkładzie.
4. Hipoteza alternatywna: rozkłady populacji są różne.

## 2 Metoda obliczania

### 2.1 Opis testu

Po przeprowadzeniu eksperymentu dla dwóch grup osobników, otrzymaliśmy odpowiednio  $n_1$  i  $n_2$  pomiarów. Chcemy sprawdzić hipotezę, że rozkłady wyników dla obu populacji są takie same ( $H_0 : G_1 = G_2$ ). Test Wilcoxona wykryje przesunięcie  $G_1$  względem  $G_2$ . Gdy podejrzewamy, że grupa pierwsza jest przesunięta w prawo względem grupy drugiej, to hipoteza alternatywna przyjmuje postać  $H_a : G_1 > G_2$ . W ogólnym przypadku, gdy nie podejrzewamy żadnego konkretnego kierunku przesunięcia, to  $H_a : G_1 \neq G_2$ .

Test Wilcoxona bazuje na uporządkowaniu wszystkich  $n = n_1 + n_2$  obserwacji. Każda obserwacja otrzymuje rangę: najmniejsza ma rangę równą 1, a największa rangę  $n$ . Statystyką testową  $W$  będzie suma rang obserwacji dla jednej z grup. Niech

$$w_1 = \text{suma rang obserwacji z grupy pierwszej.} \quad (1)$$

### 2.2 Przykład obliczania rang

Po uporządkowaniu obserwacji z dwóch grup otrzymaliśmy następującą kolejność:

Numer grupy	1	1	2	2	1	2
Ranga	1	2	3	4	5	6

Wtedy  $w_1 = 1 + 2 + 5 = 8$  oraz  $w_2 = 3 + 4 + 6 = 13$ .

## 2.3 Rozkład testu rang

W celu wyznaczenia  $wartości\_p$ , należy znać rozkład prawdopodobieństwa możliwych sum rang. Będziemy wtedy w stanie określić, jak prawdopodobne jest otrzymanie sumy rang jednej z grup, przy założeniu, że grupy pochodzą z tego samego rozkładu. Jeżeli obserwacje pochodzą z tych samych rozkładów, to każda ich kolejność (permutacja) jest tak samo prawdopodobna. To rozumowanie nasuwa następujący sposób na wyznaczenie gęstości sum rang:

1. Wyznaczyć wszystkie permutacje elementów z jednej grupy.
2. Dla każdej permutacji obliczyć sumę jej rang.
3. Częstość występowania danej sumy to prawdopodobieństwo jej otrzymania. Prawdopodobieństwo rang  $r$  i  $n_1 + n_2 - r$  są takie same – gęstość jest symetryczna.

## 2.4 Obliczanie $wartości\_p$

Założmy, że  $H_a : G_1 > G_2$ , wtedy oczekivalibyśmy, że suma rang w grupie pierwszej będzie nadzwyczaj duża, zgodnie z rozkładem sum rang. Stąd  $wartość\_p$  to

$$wartość\_p = P(W \geq w_1) \quad (2)$$

W przypadku, gdy spodziewamy się, że  $H_a : G_1 < G_2$ , to  $wartość\_p$  obliczamy analogicznie.

Dla dwustronnego testu z  $H_a : G_1 \neq G_2$ ,  $wartość\_p$  przyjmuje postać

$$wartość\_p = 2 * P(W \geq w_1), \text{ lub} \quad (3)$$

$$wartość\_p = 2 * P(W \leq w_1) \quad (4)$$

w zależności od tego, w którym kwantylu się znajdziemy.

## 3 Przybliżanie rozkładem normalnym

Jeżeli  $n_1$  i  $n_2$  są większe od 10, to statystyka  $W$  ma w przybliżeniu rozkład  $N(\mu_1, \sigma_1)$ , gdzie

$$\mu_1 = \frac{n_1(n_1 + n_2 + 1)}{2} \quad (5)$$

$$\sigma_1 = \sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}} \quad (6)$$

### 3.1 Przykład

Dane są grupy o licznosciach  $n_1 = 10$ ,  $n_2 = 12$ . Chcemy policzyć  $P(W_1 \geq 145)$ . Wiemy że

$$P(W_1 \geq w_a) \approx P(Z \geq z) \quad (7)$$

$$z = \frac{w_1 - \mu_1}{\sigma_1} \quad (8)$$

$$Z \sim N(0, 1) \quad (9)$$

Wtedy,  $\mu_1 = 10 \times (10 + 12 + 1)/2 = 115$  oraz

$$\sigma_1 = \sqrt{\frac{10 \times 12 \times (10 + 12 + 1)}{12}} = 15.16575 \quad (10)$$

$$P(W_1 \geq 145) \approx P\left(Z \geq \frac{145 - 115}{15.16575}\right) = P(Z \geq 1.978) = 0.024 \quad (11)$$

### 3.2 Uporządkowanie zawierające remisy

W przypadku występowania remisów po uporządkowaniu obserwacji, wzór na  $\sigma_1$  jest następujący

$$\sigma_1 = \sqrt{\frac{n_1 n_2}{12} \left( (n + 1) - \sum_{i=1}^k \frac{t_i^3 - t_i}{n(n-1)} \right)} \quad (12)$$

gdzie  $n = n_1 + n_2$ ,  $t_i$  to liczba różnych obserwacji z rangą  $i$ , a  $k$  to liczba różnych rang.

## Literatura

[1] <https://www.stat.auckland.ac.nz/~wild/ChanceEnc/Ch10.wilcoxon.pdf>

[2] [https://en.wikipedia.org/wiki/Mann%E2%80%93Whitney\\_U\\_test?oldformat=true](https://en.wikipedia.org/wiki/Mann%E2%80%93Whitney_U_test?oldformat=true)